

Classificação da Causa Básica de Óbito pelo Capítulo da CID-10: uma Comparação entre Random Forest e XGBoost

Arthur Meneses Neves (10425727), Danilo Oliveira Santos (10410905),
Guilherme Araujo Castro (10427775), João Victor Vidal Barbosa (10410165),
Matheus Gabriel Viana Araujo (10420444)

¹Faculdade de Computação e Informática
Universidade Presbiteriana Mackenzie (UPM)
São Paulo – SP – Brasil

e-mails institucionais: ver Tabela 1

Abstract. *This paper reports the first-bimester results of an applied AI project that classifies the underlying cause of death, aggregated into its ICD-10 chapter, from five sociodemographic attributes recorded in Brazil's Mortality Information System (SIM): age, sex, race/skin colour, schooling and state of residence. The study covers Brazil as a whole between 2000 and 2026 (32,531,918 records after preparation, 19 observed ICD-10 chapters). Random Forest and XGBoost, trained with balanced sample weights on a stratified 80/20 split, are compared against a majority-class baseline using macro-F1, per-class recall and confusion matrices. XGBoost reaches a macro-F1 of 0.1406 and Random Forest 0.1329, against 0.0224 for the baseline; absolute performance is low, which we interpret as evidence that sociodemographic attributes alone carry limited signal about the cause of death. We also describe the exploratory analysis, the data preparation, the explicit prevention of label leakage and the ethical and legal considerations of the approach.*

Resumo. *Este artigo relata os resultados do primeiro bimestre de um projeto de IA aplicada que classifica a causa básica de óbito, agregada em seu capítulo da CID-10, a partir de cinco atributos sociodemográficos registrados no Sistema de Informação sobre Mortalidade (SIM): idade, sexo, raça/cor, escolaridade e unidade da federação de residência. O recorte é o Brasil inteiro entre 2000 e 2026 (32.531.918 registros após a preparação, 19 capítulos CID-10 observados). Random Forest e XGBoost, treinados com pesos de amostra balanceados sobre uma divisão estratificada 80/20, são comparados a um baseline de classe majoritária por F1-macro, recall por classe e matrizes de confusão. O XGBoost alcança F1-macro de 0,1406 e o Random Forest 0,1329, contra 0,0224 do baseline; o desempenho absoluto é baixo, o que interpretamos como evidência de que atributos sociodemográficos isolados carregam pouco sinal sobre a causa do óbito. Descrevemos também a análise exploratória, a preparação dos dados, a prevenção explícita de vazamento de rótulo e as considerações éticas e legais da abordagem.*

Tabela 1. Integrantes do grupo (turma 7º N, Ciência da Computação).

Integrante	RA	E-mail institucional
Arthur Meneses Neves	10425727	[pendente]
Danilo Oliveira Santos	10410905	[pendente]
Guilherme Araujo Castro	10427775	[pendente]
João Victor Vidal Barbosa	10410165	[pendente]
Matheus Gabriel Viana Araujo	10420444	[pendente]

1. Introdução

1.1. Contextualização

O Sistema de Informação sobre Mortalidade (SIM) é o sistema do Ministério da Saúde que consolida as Declarações de Óbito emitidas no país. Seus microdados individuais estão disponíveis desde 1996, obtidos do DATASUS e publicados como dados abertos [Fiocruz – PCDaS 2026, Ministério da Saúde 2026]. Cada registro traz, além da causa básica do óbito codificada segundo a Classificação Internacional de Doenças, 10ª revisão (CID-10) [World Health Organization 2019], atributos sociodemográficos do falecido e dados de residência e ocorrência.

A CID-10 organiza os milhares de códigos individuais em capítulos, numerados em algarismos romanos, que agrupam causas afins — doenças do aparelho circulatório, neoplasias, causas externas, e assim por diante. Trabalhar no nível de capítulo, e não no do código completo, transforma um problema de centenas ou milhares de classes em um problema com poucas dezenas de classes, tratável com os algoritmos de aprendizado supervisionado vistos na disciplina.

Este projeto trabalha com o recorte **Brasil, âmbito nacional, período de 2000 a 2026** (2026 é um ano parcial, pois o arquivo ainda estava em formação no momento do download). A delimitação inferior em 2000 é técnica: o SIM usou a CID-9, com códigos puramente numéricos, até 1995, e não há mapeamento limpo de capítulo entre os dois esquemas de codificação.

1.2. Justificativa

Entender como fatores sociodemográficos — idade, sexo, raça/cor, escolaridade e localização — se relacionam à categoria da causa de óbito é relevante para o planejamento de políticas públicas de saúde: onde alocar recursos de prevenção, quais grupos priorizar em campanhas e quais padrões regionais merecem investigação. O tema se alinha diretamente ao Objetivo de Desenvolvimento Sustentável 3 (Saúde e Bem-Estar), cuja meta 3.4 prevê reduzir em um terço, até 2030, a mortalidade prematura por doenças não transmissíveis [Organização das Nações Unidas 2026].

Há também uma justificativa metodológica. O SIM é uma base grande, pública e heterogênea entre anos, e a própria literatura registra limitações persistentes na qualidade do preenchimento das declarações de óbito [Moraes and Costa 2017]. Medir quanto sinal existe apenas nos atributos sociodemográficos — e reportar honestamente esse limite — é um resultado útil por si só, porque delimita o que se pode e o que não se pode esperar de modelos construídos sobre esse subconjunto de variáveis.

1.3. Motivação

A motivação do grupo para este tema combina três fatores. Primeiro, o interesse em aplicar as técnicas de aprendizado de máquina da disciplina a um problema de saúde pública com impacto social claro, e não a um conjunto de dados sintético ou didático. Segundo, a disponibilidade de uma base pública, gratuita e de escala real: são 27 arquivos anuais e mais de 32 milhões de registros, um volume que obriga o grupo a lidar com questões práticas de engenharia de dados — formatos que mudam entre anos, memória, tempo de treino — que não aparecem em bases pequenas. Terceiro, o fato de a tarefa ser genuinamente difícil e de desfecho incerto: não sabíamos, ao propor o projeto, quanto da causa de óbito seria previsível a partir de variáveis sociodemográficas, e responder a essa pergunta com evidência empírica é mais instrutivo do que reproduzir um resultado já conhecido.

1.4. Objetivo

O objetivo é **classificar a causa básica de óbito, agregada em seu capítulo da CID-10**, a partir de atributos sociodemográficos registrados no SIM. Explicitamente:

- **Variáveis de entrada (atributos):** idade em anos completos (numérica), sexo (masculino, feminino), raça/cor autodeclarada (branca, preta, amarela, parda, indígena, ignorado), escolaridade (nenhuma, 1 a 3 anos, 4 a 7 anos, 8 a 11 anos, 12 anos ou mais, ignorado) e unidade da federação de residência, derivada do código do município de residência (27 categorias). São cinco variáveis.
- **Variável de saída (classes):** o capítulo da CID-10 da causa básica, com $k = 19$ classes efetivamente observadas nos dados (capítulos I a XVIII e XX; os capítulos XIX e XXI nunca ocorrem como causa básica nesta base). A lista completa das classes e sua frequência estão na Tabela 3.
- **Período:** 2000 a 2026, sendo 2026 um ano parcial.
- **Região:** Brasil, âmbito nacional, sem recorte por estado ou região.

Nenhuma variável que descreva a cadeia de causas da própria declaração de óbito (campos LINHAA–LINHAD, CIRCOBITO, CAUSABAS_O) é usada como entrada, para evitar vazamento do rótulo; a Seção 3 detalha como isso é garantido e verificado em código.

1.5. Contribuições esperadas

1. Uma análise exploratória documentada e reproduzível do SIM 2000–2026, incluindo as inconsistências de formato entre anos e a evolução do não-preenchimento de raça/cor e escolaridade.
2. Uma função de mapeamento CAUSABAS → capítulo CID-10 reutilizável, com testes automatizados, e uma rotina única de preparação dos dados compartilhada por todos os notebooks.
3. Uma comparação entre um baseline de classe majoritária, Random Forest e XG-Boost para essa tarefa, com discussão explícita de desempenho por classe, custo computacional, desbalanceamento e limitações.
4. Uma medida empírica de quanto sinal sobre a causa de óbito existe apenas em atributos sociodemográficos, reportada sem superestimação.

2. Fundamentação Teórica e Trabalhos Relacionados

2.1. Conceitos fundamentais

O problema tratado é de **classificação supervisionada multiclasse**: dado um vetor de atributos x , atribuir a ele um rótulo y entre k classes mutuamente exclusivas, aprendendo a associação a partir de exemplos rotulados. Os dois algoritmos comparados pertencem à família dos *ensembles* de árvores de decisão, hoje o padrão de referência para dados tabulares.

Random Forest [Breiman 2001] treina um conjunto de árvores de decisão, cada uma sobre uma amostra bootstrap dos dados e com uma seleção aleatória de atributos em cada nó; a predição final é o voto da maioria. A aleatorização reduz a correlação entre as árvores, e o erro de generalização da floresta depende da força das árvores individuais e dessa correlação. É um método robusto a atributos irrelevantes e de treino naturalmente paralelizável.

XGBoost [Chen and Guestrin 2016] implementa *gradient boosting*: as árvores são construídas em sequência, cada uma ajustada ao erro residual das anteriores, com regularização explícita da complexidade. O trabalho original descreve um algoritmo consciente de esparsidade, para dados esparsos, e um esquema aproximado de busca de pontos de corte baseado em quantis ponderados (*weighted quantile sketch*), além de otimizações de acesso a cache, compressão e particionamento dos dados — o conjunto dessas técnicas é o que torna o método viável em bases com dezenas de milhões de linhas, como a nossa. Nos experimentos deste trabalho usamos o modo `tree_method = "hist"`, que é um mecanismo distinto, de discretização dos atributos em histogramas de *bins*, também voltado a bases grandes.

Dois conceitos adicionais estruturam a metodologia. O primeiro é o **desbalanceamento de classes**: quando uma classe domina a base, a acurácia deixa de ser informativa, porque um classificador trivial que sempre prevê a classe majoritária já a maximiza. Por isso adotamos o **F1-macro**, que é a média aritmética simples do F1 de cada classe e, portanto, dá o mesmo peso a um capítulo com 8,8 milhões de registros e a um com 629, além do recall por classe e da matriz de confusão. O segundo é o **vazamento de rótulo** (*label leakage*): a presença, entre os atributos, de informação que só existe porque o rótulo já é conhecido. Em uma base de declarações de óbito o risco é concreto, já que os campos de descrição da cadeia de causas são, na prática, o próprio rótulo em outra forma.

A implementação usa a biblioteca `scikit-learn` [Pedregosa et al. 2011] (versão 1.9.1) para o baseline, o Random Forest, a codificação dos atributos, a divisão estratificada e as métricas, e a biblioteca `XGBoost` (versão 3.4.1) para o *gradient boosting*.

2.2. Trabalhos relacionados

Classificação da causa de óbito em CID-10 a partir de laudos. [Mujtaba et al. 2017] classificaram automaticamente a causa de óbito em 9 categorias da CID-10 a partir do texto livre de 2.200 laudos de necropsia relacionados a acidentes, em um hospital de Kuala Lumpur. Compararam cinco classificadores (Naive Bayes, SVM, k-NN, J48 e Random Forest) combinados com seis estratégias de seleção de atributos; a melhor solução foi o Random Forest com seleção de atributos guiada por especialistas, atingindo cerca de 90% de acurácia e de F-medida macro com 30 atributos. O contraste com o nosso

trabalho é instrutivo e orientou uma decisão metodológica: o alto desempenho ali vem de entradas que *descrevem clinicamente o óbito* (exame externo, lesões, exame interno, histórico médico). No SIM, o análogo desses campos são justamente LINHAA–LINHAD e CIRCOBITO, que decidimos não usar por serem vazamento de rótulo para o nosso objetivo. Ou seja, os dois trabalhos resolvem problemas diferentes: lá, automatizar a codificação a partir da descrição clínica; aqui, medir a associação entre perfil sociodemográfico e categoria de causa.

Aprendizado de máquina sobre desfechos de óbito no Brasil. [Silva and Silva Neto 2022] compararam Regressão Logística, Árvore de Decisão e Random Forest para prever óbito por COVID-19 a partir de dados clínicos de 134.639 pacientes do SUS atendidos entre janeiro e setembro de 2021. A melhor solução foi o Random Forest, com 77% de acurácia e AUC-ROC de 0,75, tendo suporte ventilatório, internação em UTI, idade e comorbidades como fatores mais importantes. [Santos et al. 2019] aplicaram cinco algoritmos (regressão logística, regressão logística penalizada, redes neurais, *gradient boosted trees* e Random Forest) a 2.808 idosos do estudo SABE, em São Paulo, para prever óbito em cinco anos a partir de 37 preditores demográficos, socioeconômicos e de saúde; todos os modelos superaram AUC-ROC de 0,70, com melhor resultado para redes neurais e regressão logística penalizada. Os dois trabalhos são binários (o óbito ocorre ou não) e contam com preditores clínicos, enquanto o nosso é multiclasse com 19 categorias e usa apenas cinco variáveis sociodemográficas — o que ajuda a dimensionar por que o nosso desempenho absoluto é bem menor. Deles retiramos duas decisões: comparar mais de um algoritmo sob o mesmo protocolo, em vez de reportar um modelo isolado, e relatar métricas que não dependam apenas da acurácia.

Qualidade da informação no SIM. [Morais and Costa 2017] avaliaram o próprio SIM como sistema de informação, a partir de 45 indicadores de qualidade aplicados a profissionais e gestores de saúde no nordeste do estado de São Paulo. Embora 31 indicadores tenham recebido avaliação positiva, cerca de 47% dos usuários relataram algum grau de informação incorreta, especialmente na causa de óbito registrada na declaração, além de problemas de integração com outros sistemas. Esse achado sustenta uma escolha nossa de preparação de dados: tratar os códigos de “ignorado” como uma categoria explícita em vez de imputá-los, já que o não-preenchimento é um fenômeno real e sistemático da base, e escondê-lo por imputação estatística mascararia um viés conhecido.

Lacuna que este trabalho ocupa. Nenhum dos trabalhos acima classifica a *categoria* da causa entre óbitos já registrados usando somente atributos sociodemográficos do SIM em escala nacional e em série histórica longa. É essa combinação — tarefa multiclasse, base nacional completa, conjunto de atributos deliberadamente restrito e livre de vazamento — que caracteriza a contribuição deste projeto. A comparação contra um baseline de classe majoritária, e não apenas entre os dois modelos, é necessária precisamente porque, com 27% dos óbitos concentrados em um único capítulo, qualquer métrica global pode parecer razoável sem que o modelo tenha aprendido nada de útil.

3. Metodologia e Resultados Esperados

3.1. Abordagem e etapas

A solução foi desenvolvida em Python, organizada em três notebooks (01_eda_exploratoria.ipynb, 02_preparacao_dados.ipynb

e `03_resultados_parciais.ipynb`) e um módulo de funções (`src/simutils.py`) coberto por testes automatizados. As etapas são:

1. **Leitura e harmonização dos arquivos brutos.** Os 27 CSVs anuais são lidos por uma única função, que resolve as diferenças de formato entre anos descritas na Seção 3.2.
2. **Análise exploratória** (notebook 01): distribuições demográficas, distribuição e tendência dos capítulos CID-10, sazonalidade e perfil de valores ausentes por ano.
3. **Preparação** (notebook 02): decodificação da idade, harmonização de escolaridade e raça/cor, derivação da UF a partir do município, derivação do alvo (capítulo CID-10) e aplicação dos filtros, com contabilidade de linhas descartadas em cada etapa.
4. **Definição do protocolo de avaliação antes do treino:** divisão estratificada, tratamento do desbalanceamento, métricas e verificação de ausência de vazamento (detalhados abaixo).
5. **Treino e avaliação** (notebook 03) do baseline, do Random Forest e do XGBoost, sobre o mesmo conjunto de treino e o mesmo conjunto de teste, seguidos de uma checagem suplementar de generalização temporal.

Divisão treino/teste. O protocolo principal é uma divisão aleatória **estratificada por classe**, 80% para treino e 20% para teste, com `random_state = 42`: 26.025.534 linhas de treino e 6.506.384 de teste. A maior diferença absoluta de proporção de classe entre treino e teste é de $8,52 \times 10^{-8}$, ou seja, a distribuição do alvo é preservada nos dois conjuntos, inclusive para os capítulos raros. O conjunto de teste é o mesmo para os três modelos e nunca é subamostrado.

Codificação dos atributos. As quatro variáveis categóricas recebem codificação *one-hot* densa em `float32` e a idade entra como valor numérico, resultando em 42 colunas. O codificador é ajustado apenas sobre o conjunto de treino e depois aplicado ao teste, para que nenhuma informação do teste influencie a preparação.

Tratamento do desbalanceamento. Com 19 classes e razão de 13.972 entre a maior e a menor (Seção 3.2), treinar sem correção faria a função de perda ser dominada pelos capítulos grandes. Adotamos, então, **pesos de amostra balanceados**, iguais para Random Forest e XGBoost, calculados como $n/(k \cdot n_c)$ para cada classe c . Os pesos vão de 0,1948 (capítulo IX, o majoritário) a 2.723,19 (capítulo VII, o minoritário), razão de 13.977. Essa escolha tem um custo previsto e assumido: ela sacrifica a acurácia nas classes frequentes em troca de recall nas raras, e por isso a acurácia entra no artigo apenas como referência, nunca como critério de sucesso.

Métricas. O critério principal é o **F1-macro**. Reportamos também o **recall por classe** para todas as 19 classes e a **matriz de confusão** normalizada por linha (em que a diagonal é o recall), além da acurácia e do recall macro como referências, e do tempo de treino de cada modelo como medida de custo computacional.

Prevenção de vazamento de rótulo. A prevenção é estrutural e verificada. Estrutural, porque a leitura dos CSVs carrega apenas 8 colunas (`TIPOBITO`, `DTOBITO`, `IDADE`, `SEXO`, `RACACOR`, `ESC`, `CODMUNRES` e `CAUSABAS`), de modo que os campos da cadeia de causas (`LINHAA-LINHAD`, `CIRCOBITO`, `CAUSABAS_O`) nunca entram em memória, ainda que existam nos arquivos originais. Verificada, porque o notebook

de modelagem contém asserções que falham se alguma entrada for o rótulo, o código CAUSABAS original, o município detalhado, o ano do arquivo ou qualquer coluna cujo nome comece por LINHA. As entradas e o rótulo são declarados uma única vez, como constantes do módulo (FEATURE_COLUMNS e TARGET_COLUMN), e importados pelos notebooks, o que impede que as listas divirjam entre arquivos.

Chechagem suplementar de generalização temporal. Além do protocolo principal, treinamos os dois modelos com os anos de 2000 a 2022 e os avaliamos em 2023, 2025 e 2026, para verificar se o desempenho se mantém em anos nunca vistos. Essa checagem *não substitui* a divisão estratificada; ela responde a outra pergunta e é apresentada separadamente.

Resultados esperados. Dado o conjunto restrito de atributos, era plausível esperar desempenho modesto em termos absolutos, mas claramente superior ao baseline em F1-macro, com acerto melhor nos capítulos fortemente associados a idade e sexo (gravidez e parto; afecções perinatais; causas externas) e acerto fraco nas causas de adultos e idosos, que competem entre si no mesmo perfil demográfico. A Seção 4 mostra que foi isso o que ocorreu.

3.2. Dataset

Origem e endereço. Arquivos “Mortalidade Geral” do SIM, mantido pelo Ministério da Saúde, obtidos no Portal Brasileiro de Dados Abertos em <https://dados.gov.br/dados/conjuntos-dados/sim-1979-2019> [Ministério da Saúde 2026]. O título do conjunto no portal menciona o intervalo 1979–2019, mas a página disponibiliza também os arquivos anuais posteriores: os arquivos efetivamente baixados e usados aqui cobrem 2000–2026, conforme registrado em `data/README.md`. **Licença:** Creative Commons Atribuição (CC-BY). **Formato:** CSV separado por ponto e vírgula, codificação `latin1`, um arquivo por ano. **Volume:** 27 arquivos (2000 a 2026), aproximadamente 8,5 GB, **32.629.071 registros brutos**. Os arquivos não são versionados no repositório, por serem um download público de grande porte; o diretório `data/` contém um `README.md` com a origem, o procedimento de download e a descrição das colunas, conforme orienta o próprio enunciado do projeto.

Conteúdo. Cada registro corresponde a uma Declaração de Óbito. O número de colunas cresce de 39 (2000) para 88 (2024) ao longo da série, conforme o SIM incorporou novos campos. Este projeto lê 8 colunas, presentes com o mesmo nome em todos os anos conferidos, listadas na Tabela 2. Todos os registros desses arquivos são de óbitos não fetais (TIPOBITO = 2), o que foi verificado no quadro final.

Análise exploratória. A exploração (notebook 01) revelou quatro problemas de qualidade que definiram a preparação:

1. **Formatos divergentes entre anos.** Os arquivos de 2022 e 2023 não possuem linha de cabeçalho (e o de 2023 não possui o campo NECROPSIA, o que desloca todas as colunas seguintes); a data do óbito aparece em três formatos distintos (`ddmmaaaa`, `dd-mm-aaaa` e inteiro sem zero à esquerda); e CODMUNRES mistura códigos IBGE de 6 e de 7 dígitos para o mesmo município (355030 e 3550308 são ambos São Paulo). Cada um desses casos é tratado na função de leitura, com validação que falha explicitamente se o arquivo divergir do esquema esperado, e com testes automatizados.

Tabela 2. Colunas lidas dos arquivos brutos e seu papel no projeto.

Coluna	Significado	Papel
IDADE	Idade codificada (unidade + valor)	Entrada (decodificada em anos)
SEXO	0 ignorado, 1 masculino, 2 feminino	Entrada
RACACOR	Raça/cor autodeclarada (1 a 5)	Entrada
ESC	Escolaridade (1 a 5, 9 ignorado)	Entrada
CODMUNRES	Município de residência (IBGE)	Entrada (agregada em UF)
CAUSABAS	Causa básica do óbito (CID-10)	Rótulo (capítulo)
DTOBITO	Data do óbito	Só análise exploratória
TIPOBITO	1 fetal, 2 não fetal	Só verificação

2. **Dois tipos de “sem informação”.** ESC e RACACOR têm tanto valores ausentes quanto o código 9 (“ignorado”), que é um valor preenchido e não é capturado por uma contagem de nulos. Em 2000, ESC era ausente em 19,55% dos registros e igual a 9 em outros 24,55%.
3. **Não-preenchimento que muda muito ao longo do tempo** (Figura 1). A ausência de RACACOR cai de 15,90% (2000) para 1,23% (2026), e a de ESC vai de 19,55% (2000), com pico de 22,82% em 2003, a 4,89% (2026). Essa melhora é real, mas significa que registros antigos e recentes não são comparáveis em qualidade — uma limitação relevante, coerente com os problemas de preenchimento relatados na avaliação do sistema por [Morais and Costa 2017].
4. **Mudança na composição das causas.** Entre 2000 e 2025, a participação das causas mal definidas (capítulo XVIII) cai de 14,34% para 4,97%, enquanto neoplasias sobem de 12,73% para 17,49% e doenças do aparelho respiratório de 9,33% para 13,14%; as doenças do aparelho circulatório recuam de 27,53% para 25,74% e as causas externas de 12,51% para 10,16%. A queda das causas mal definidas indica melhora na investigação dos óbitos, mas também implica que o alvo não é estacionário ao longo da série.




Figura 1. Percentual de registros com RACACOR e ESC ausentes, por ano (2000–2026). O código 9 (“ignorado”), que é um valor preenchido, não aparece nesta contagem e é tratado à parte.

Preparação e estratégia de tratamento. A preparação é feita por uma única função, compartilhada por todos os notebooks, e seu resultado é armazenado em cache (Parquet) cuja chave inclui o tamanho e a data de modificação de cada CSV e uma constante de versão, de modo que um cache desatualizado nunca é usado silenciosamente. As decisões foram:

- **Idade:** decodificada para anos completos a partir do código do SIM (primeiro dígito indica a unidade — minutos, horas, dias, meses, anos — e os dois últimos, o valor).
- **Escolaridade e raça/cor:** mapeadas para categorias nomeadas, com “**Ignorado**” como categoria explícita em vez de imputação. Nenhuma linha é descartada por esse motivo: “Ignorado” soma 26,409% em ESC (8.616.946 registros) e 5,389% em RACACOR (1.758.238). Descartar essas linhas enviesaria a amostra contra os anos iniciais da série. O código 0 de ESC, que aparece apenas em 2009 a 2012 e em 2014 (231.933 registros, 0,711%) e não consta do dicionário do SIM, foi mapeado para “Ignorado”; essa é uma decisão discutível, isolada em uma única constante do código e revisável.
- **Município:** truncado para 6 dígitos e agregado em **unidade da federação**. O modelo nunca vê o município: são cerca de 5.600 municípios distintos, o que inviabilizaria a codificação one-hot e, principalmente, aumentaria o risco de reidentificação em células pequenas (Seção 4.1). As 27 UFs estão todas presentes, de São Paulo (23,196% dos registros) a Roraima (0,175%).
- **Filtros, com contabilidade.** Foram descartados 15.842 registros com SEXO ignorado (0,0486%), 81.308 com idade desconhecida (0,2492%) e 3 cujo CAUSABAS não corresponde a nenhum capítulo da CID-10. O total descartado é de 97.153 registros (0,2977% do bruto), restando **32.531.918 registros e 19 classes**, sem nenhum valor nulo em nenhuma coluna.

Distribuição do alvo. A Tabela 3 e a Figura 2 mostram as 19 classes. O capítulo IX (doenças do aparelho circulatório) concentra 27,0141% dos registros, e o capítulo VII (doenças do olho e anexos), 0,0019% — uma razão de 13.972 entre o maior e o menor. Cinco capítulos ficam abaixo de 0,5% dos registros. É esse quadro, e não uma preferência genérica por “robustez em dados tabulares”, que justifica as escolhas metodológicas: com 19 classes e essa razão de desbalanceamento, são necessários um baseline explícito, pesos balanceados e métricas macro-agregadas para que o resultado signifique alguma coisa.

4. Resultados Parciais

4.1. Aspectos éticos e responsabilidade no uso da IA

Privacidade e LGPD. O projeto usa exclusivamente os microdados públicos do SIM, publicados como dados abertos pelo Ministério da Saúde sob licença CC-BY, e os utiliza como foram disponibilizados. Das 8 colunas lidas, nenhuma é identificador direto (nome, CPF, endereço). A Lei Geral de Proteção de Dados Pessoais [Brasil 2018] define dado anonimizado como aquele “relativo a titular que não possa ser identificado, considerando a utilização de meios técnicos razoáveis e disponíveis na ocasião de seu tratamento” (art. 5º, inciso III) e estabelece, no art. 12, que dados anonimizados não são considerados dados pessoais, *salvo* quando a anonimização puder ser revertida com esforços razoáveis. É exatamente essa ressalva que nos obriga a cuidado: a combinação

Tabela 3. Distribuição do alvo: capítulos da CID-10 observados em 32.531.918 registros (SIM, Brasil, 2000–2026).

Cap.	Descrição	Registros	%
IX	Doenças do aparelho circulatório	8.788.199	27,0141
II	Neoplasias (tumores)	5.108.490	15,7030
XX	Causas externas de morbidade e mortalidade	3.712.335	11,4114
X	Doenças do aparelho respiratório	3.516.512	10,8094
XVIII	Sintomas, sinais e causas mal definidas	2.328.478	7,1575
I	Doenças infecciosas e parasitárias	2.108.449	6,4812
IV	Doenças endócrinas, nutricionais e metabólicas	1.896.126	5,8285
XI	Doenças do aparelho digestivo	1.614.124	4,9617
XIV	Doenças do aparelho geniturinário	879.273	2,7028
VI	Doenças do sistema nervoso	854.902	2,6279
XVI	Afecções originadas no período perinatal	632.965	1,9457
V	Transtornos mentais e comportamentais	336.307	1,0338
XVII	Malformações congênitas e anomalias cromossômicas	271.194	0,8336
III	Doenças do sangue e transtornos imunitários	165.129	0,5076
XII	Doenças da pele e do tecido subcutâneo	134.961	0,4149
XIII	Doenças do sistema osteomuscular e tecido conjuntivo	132.556	0,4075
XV	Gravidez, parto e puerpério	46.798	0,1439
VIII	Doenças do ouvido e da apófise mastoide	4.491	0,0138
VII	Doenças do olho e anexos	629	0,0019

de quase-identificadores (idade, município de residência e data do óbito) pode permitir reidentificação por inferência em municípios pequenos ou para causas raras. As medidas concretas adotadas são:

- **Uso restrito a dados públicos e anonimizados**, sem qualquer tentativa de reidentificação e sem cruzamento com outras bases.
- **Minimização de atributos**. Os modelos usam cinco variáveis, e a localização entra apenas no nível de UF: CODMUNRES é reduzido a município de 6 dígitos e daí a UF, e somente a UF é entrada do modelo. A data completa do óbito é lida na exploração, mas não entra no quadro de modelagem, que guarda apenas o ano do arquivo. Assim, nos modelos e nos resultados de classificação, nada é reportado abaixo do nível de UF.
- **Supressão de grupos pequenos**. O grupo adota a política de **suprimir de qualquer material publicado toda célula de resultado com menos de 10 casos** (por exemplo, cruzamentos UF × capítulo ou município × capítulo). Registre-se que essa é uma política adotada, *ainda não implementada em código*. Na situação atual ela não é acionada pelos resultados de classificação: a menor classe (capítulo VII) tem 629 registros no total e 126 no conjunto de teste, e a menor UF (Roraima) tem 56.878 registros. As tabelas exploratórias dos notebooks são material de diagnóstico, não resultados publicados; nelas, as únicas contagens abaixo de 10 são o código 9 de RACACOR, que ocorre 5 vezes em todo o período, e os 3 registros sem capítulo CID-10 — em ambos os casos, contagens nacionais de uma única variável, sem cruzamento com município.




Figura 2. Participação de cada capítulo da CID-10 no total de registros, em escala logarítmica. Os capítulos XIX e XXI não aparecem porque nunca ocorrem como causa básica nesta base.

- **Tratamento dos arquivos.** Os CSVs brutos e o cache derivado não são versionados no repositório público; ficam versionados apenas o código, os resultados agregados e a documentação.

Vazamento de rótulo como questão ética, e não apenas técnica. Um modelo que “acertasse” a causa porque leu a descrição da causa não mediria associação nenhuma, e reportá-lo como resultado seria enganoso. A prevenção estrutural e verificada em código descrita na Seção 3 é, portanto, também uma exigência de honestidade na apresentação dos resultados.

Viés de dados. O não-preenchimento de RACACOR e ESC é grande e muda muito ao longo dos anos (Figura 1). Um modelo treinado sobre esses dados herda qualquer padrão sistemático desse não-preenchimento — por exemplo, se a ausência for mais comum em certos serviços de saúde ou regiões, algo que não medimos. Por isso mantemos “Ignorado” como categoria explícita em vez de imputar valores, o que esconderia o viés em vez de expô-lo. Reconhecemos como limitação que ainda não realizamos análise de erro por subgrupo (raça/cor, sexo, UF), prevista para a etapa seguinte do projeto.

Uso pretendido e mau uso. O objetivo é apoiar o planejamento em saúde pública em nível agregado. O modelo **não deve** ser usado para decisões individuais sobre pessoas vivas, nem para inferir a causa de uma morte específica sem o laudo médico, que é a fonte de verdade. O desempenho absoluto medido (Seção 4.2) reforça essa restrição: um F1-macro em torno de 0,14 é incompatível com qualquer uso individual.

Transparência. O alvo é o capítulo da CID-10, e não o código completo. Além de evitar centenas de classes, isso produz uma categoria ampla e auditável, que reduz o risco de decisões automatizadas granulares e mal calibradas a partir de poucas variáveis sociodemográficas. Todo o código, incluindo a preparação e as asserções de ausência de

vazamento, é público.

Necessidade de submissão ao Comitê de Ética em Pesquisa (CEP). O projeto usa exclusivamente dados públicos, secundários e anonimizados, sem acesso a registros identificáveis, sem vinculação com outras bases e sem contato com pessoas. A Resolução CNS nº 510/2016 [Conselho Nacional de Saúde 2016], em seu art. 1º, parágrafo único, determina que não serão registradas nem avaliadas pelo sistema CEP/CONEP, entre outras, a “pesquisa que utilize informações de acesso público, nos termos da Lei nº 12.527, de 18 de novembro de 2011” (inciso II) e a “pesquisa que utilize informações de domínio público” (inciso III). Registre-se que essa resolução dispõe especificamente sobre pesquisas em Ciências Humanas e Sociais, de modo que sua aplicação a este projeto é analógica. Ainda assim, os três critérios que sustentam a dispensa se aplicam integralmente aqui: os dados são *públicos*, *secundários* (não foram coletados pelo grupo, nem houve contato com participantes) e *anonimizados*, no sentido do art. 5º, inciso III, da LGPD [Brasil 2018]. Por esses critérios, e em linha com a orientação da disciplina, o grupo conclui que, em princípio, a submissão ao CEP não é necessária. Isso mudaria se o projeto passasse a usar registros identificáveis ou de acesso restrito, cruzasse o SIM com outra base ou envolvesse contato direto com pessoas; nenhuma dessas condições se aplica hoje, e, se alguma passar a valer, a necessidade de submissão deve ser reavaliada antes de prosseguir.

4.2. Detalhamento dos resultados parciais

Os três modelos foram treinados sobre as 26.025.534 linhas de treino *completas*, sem subamostragem, e avaliados sobre as mesmas 6.506.384 linhas de teste, em um servidor Linux, com treino paralelizado em todos os núcleos disponíveis (`n_jobs = -1`). As configurações são iniciais e nenhum hiperparâmetro foi ajustado: baseline de classe majoritária; Random Forest com 100 árvores e profundidade máxima 12; XGBoost com 100 rodadas, profundidade 6, taxa de aprendizado 0,3 e `tree_method = "hist"`. Os dois modelos receberam os mesmos pesos de amostra balanceados.

Tabela 4. Comparação dos três modelos no conjunto de teste (6.506.384 linhas, divisão estratificada 80/20). A acurácia consta apenas como referência.

Modelo	F1-macro	Acurácia	Recall macro	Tempo de treino
Baseline (classe majoritária)	0,0224	0,2701	0,0526	3,1 s
Random Forest	0,1329	0,1625	0,2234	343,9 s
XGBoost	0,1406	0,1755	0,2294	983,3 s

(a) Margem sobre o baseline. Em F1-macro, o Random Forest supera o baseline em +0,1105 (5,9 vezes) e o XGBoost em +0,1183 (6,3 vezes). Os dois modelos também superam o baseline em recall macro (0,2234 e 0,2294 contra 0,0526). Em acurácia, porém, o baseline vence (0,2701 contra 0,1625 e 0,1755). Esse resultado não é um defeito, e sim a consequência direta e prevista dos pesos balanceados: o baseline atinge 27% de acurácia prevendo sempre o capítulo IX e errando todas as outras 18 classes, enquanto os modelos ponderados distribuem suas predições entre as classes e abrem mão dos acertos fáceis na classe majoritária. É precisamente por isso que a acurácia não é o critério deste trabalho.

(b) Desempenho por classe. A Tabela 5 traz o recall das 19 classes nos três modelos. O baseline tem recall 1,0 no capítulo IX e **zero em 18 classes**; Random Forest

e XGBoost não deixam nenhuma classe com recall exatamente zero, embora no Random Forest os capítulos III (0,0004) e IX (0,0013) tenham recall praticamente nulo. Apenas os capítulos XV (gravidez, parto e puerpério) e XVI (perinatal) ultrapassam 0,5 de recall nos dois modelos; o capítulo XX (causas externas) ultrapassa 0,5 somente no Random Forest (0,5363 contra 0,4975 do XGBoost). Esse padrão corresponde ao que era plausível esperar (Seção 3): idade e sexo quase determinam XV e XVI, mas dizem pouco sobre as causas que competem entre si na população adulta e idosa.

Tabela 5. Recall por classe nos três modelos, com o suporte de cada classe no conjunto de teste.

Cap.	Descrição	Suporte	Baseline	RF	XGBoost
I	Infecciosas	421.690	0,0000	0,0224	0,0281
II	Neoplasias	1.021.698	0,0000	0,1765	0,2473
III	Sangue/imunitário	33.026	0,0000	0,0004	0,0058
IV	Endócrinas	379.225	0,0000	0,1546	0,1491
V	Mentais	67.261	0,0000	0,3006	0,3058
VI	Nervoso	170.980	0,0000	0,2794	0,2767
VII	Olho	126	0,0000	0,0794	0,0476
VIII	Ouvido	898	0,0000	0,0278	0,0768
IX	Circulatório	1.757.640	1,0000	0,0013	0,0260
X	Respiratório	703.302	0,0000	0,1099	0,1011
XI	Digestivo	322.825	0,0000	0,0763	0,0805
XII	Pele	26.992	0,0000	0,0987	0,1236
XIII	Osteomuscular	26.511	0,0000	0,0886	0,0454
XIV	Geniturinário	175.855	0,0000	0,0593	0,1022
XV	Gravidez/parto	9.360	0,0000	0,9701	0,9754
XVI	Perinatal	126.593	0,0000	0,8602	0,8373
XVII	Malformações	54.239	0,0000	0,2003	0,2404
XVIII	Mal definidas	465.696	0,0000	0,2023	0,1924
XX	Causas externas	742.467	0,0000	0,5363	0,4975

(c) Leitura das matrizes de confusão. As Figuras 3 e 4 mostram as matrizes normalizadas por linha, em que a diagonal é o recall e cada linha soma 1 — normalização necessária para que classes raras sejam visíveis ao lado de um capítulo com 1,75 milhão de casos de teste. Nos dois modelos a diagonal só se destaca em XV, XVI e XX. A confusão mais sistemática ocorre entre XVII (malformações congênicas) e XVI (perinatal): no Random Forest, 60% dos casos de XVII são previstos como XVI, o que é plausível, já que as duas causas se concentram nas primeiras idades e o modelo só enxerga idade, sexo, raça/cor, escolaridade e UF. Fora desses blocos, as predições se espalham amplamente, o que é a expressão visual do baixo desempenho global.

(d) Classes raras. Nos capítulos VII (olho) e VIII (ouvido), os números são apenas indicativos. Em VII, com 126 casos de teste, o Random Forest acerta 10 e o XGBoost 6, com precisão praticamente nula nos dois — consequência esperada do peso de amostra de 2.723 atribuído a essa classe, que leva o modelo a prever VII para muitas linhas de outras classes. Em VIII, com 898 casos, o Random Forest acerta 25 e o XGBoost 69. O capítulo XV, apesar de raro (9.360 casos), é o mais fácil de reconhecer (recall




Figura 3. Random Forest: matriz de confusão normalizada por linha. A figura serve à leitura do padrão de confusão entre capítulos; os valores exatos da diagonal (o recall de cada classe) estão na Tabela 5.

0,9701 e 0,9754), mas com precisão de apenas 0,039 nos dois modelos, porque muitas mulheres jovens morrem de outras causas. Nenhum capítulo foi fundido ou removido.

(e) XGBoost contra Random Forest: o ganho compensa o custo? O XGBoost obteve F1-macro 0,0078 maior (cerca de 6% em termos relativos) gastando 983,3 s contra 343,9 s de treino, ou seja, 2,86 vezes mais tempo. Na checagem temporal a razão foi ainda maior (1.322,3 s contra 352,9 s). O ganho aparece em alguns capítulos (II: 0,2473 contra 0,1765; XIV: 0,1022 contra 0,0593; IX: 0,0260 contra 0,0013) e se inverte em outros (XVI: 0,8602 contra 0,8373; XX: 0,5363 contra 0,4975; XIII: 0,0886 contra 0,0454). Como as duas configurações iniciais têm profundidades diferentes (12 e 6) e nenhuma foi ajustada, esta comparação *não* mostra qual família é superior após ajuste fino. Nossa leitura, para o estágio atual: o Random Forest é a opção mais barata e chega perto; o XGBoost passa a valer o custo se o ajuste de hiperparâmetros ampliar a vantagem, o que ainda precisa ser verificado.

(f) Checagem suplementar de generalização temporal. Treinando com 2000–




Figura 4. XGBoost: matriz de confusão normalizada por linha. Como na Figura 3, os valores exatos da diagonal estão na Tabela 5.

2022 (27.506.105 linhas) e testando em anos não vistos (Tabela 6), o F1-macro cai de forma leve e monótona: 0,0051 do Random Forest e 0,0053 do XGBoost entre 2023 e 2026. O F1-macro agregado do teste temporal fica cerca de 0,01 abaixo do protocolo principal. Essa comparação, porém, *não isola* a deriva temporal, porque o conjunto de treino tem outro tamanho e o de teste é um conjunto diferente de anos, com outra mistura de classes; o baseline não foi recalculado nessa checagem. A mudança na qualidade do preenchimento ao longo dos anos é uma explicação possível para a deriva, mas não foi testada. O ano de 2026 é parcial (506.027 linhas contra 1.463.485 em 2023), o que torna seu F1-macro menos estável.

Tabela 6. Checagem suplementar de generalização temporal: treino com 2000–2022, teste em anos não vistos. F1-macro.

Modelo	2023	2025	2026 (parcial)	Agregado
Random Forest	0,1253	0,1216	0,1202	0,1230
XGBoost	0,1340	0,1297	0,1287	0,1314

(g) Interpretação honesta do desempenho absoluto. O resultado principal é que **o desempenho absoluto é baixo**: um F1-macro de 0,13 a 0,14 significa que a maioria dos 19 capítulos é reconhecida de forma fraca. O ganho sobre o baseline é real e grande em termos relativos, e mostra que os modelos aprenderam algo — mas o que eles aprenderam é, essencialmente, o efeito de idade e sexo sobre um punhado de capítulos. Nossa interpretação é que cinco atributos sociodemográficos carregam *pouco* sinal sobre a categoria da causa básica de óbito, o que é em si uma informação relevante: a maior parte dos óbitos ocorre em adultos e idosos, faixa em que os capítulos principais (circulatório, neoplasias, respiratório, endócrino) competem dentro do mesmo perfil demográfico. Não apresentamos esses números como um classificador utilizável, e sim como a medida de um limite.

4.3. Limitações e próximos passos (N2)

As limitações reconhecidas são: (i) uma única divisão e uma única semente, sem intervalos de confiança; (ii) hiperparâmetros não ajustados, com profundidades diferentes entre os dois modelos; (iii) conclusões sobre os capítulos VII e VIII apoiadas em 126 e 898 casos de teste; (iv) ausência de análise de erro por subgrupo; (v) a decisão de mapear o código 0 de ESC para “Ignorado”, que pode significar “nenhuma escolaridade”; e (vi) a política de supressão de células com menos de 10 casos ainda não implementada em código.

Para o segundo bimestre, os caminhos previstos são: ajuste de hiperparâmetros dos dois modelos sob o mesmo protocolo; avaliação de atributos adicionais que comprovadamente não vazem o rótulo (por exemplo, local de ocorrência e assistência médica, mediante verificação explícita); inclusão de variáveis temporais, como mês e ano do óbito; variáveis agregadas em nível de município com granularidade suficiente para respeitar a supressão de grupos pequenos; e análise de erro por subgrupo, para avaliar equidade. A expectativa, dado o que foi medido aqui, é de ganhos moderados: o limite observado parece vir do conjunto de atributos, não da escolha do algoritmo.

4.4. Endereço do repositório no GitHub

Todo o material do projeto está em um repositório **público**: <https://github.com/araujoviana/projeto1-IA-2026>. Ele contém este artigo (fontes LaTeX e PDF), a descrição do dataset e o procedimento para obtê-lo (`data/README.md`, sem os microdados brutos, que são um download público de grande porte), os três notebooks Python executados com seus resultados (`notebooks/`), o módulo de funções com testes automatizados (`src/` e `tests/`) e o histórico completo de alterações no Git. Todos os arquivos-fonte abrem com um cabeçalho contendo a identificação dos integrantes, a síntese do conteúdo do arquivo e o histórico de alterações no formato “data — autor — descrição”.

Referências

Brasil (2018). Lei nº 13.709, de 14 de agosto de 2018. lei geral de proteção de dados pessoais (LGPD). Diário Oficial da União, Brasília, DF. https://www.planalto.gov.br/ccivil_03/_ato2015-2018/2018/lei/113709.htm. Acesso em: 24 set. 2026.

- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1):5–32. DOI: 10.1023/A:1010933404324.
- Chen, T. and Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '16)*, pages 785–794. ACM. Pré-impressão: <https://arxiv.org/abs/1603.02754>.
- Conselho Nacional de Saúde (2016). Resolução nº 510, de 7 de abril de 2016. Ministério da Saúde, Brasília, DF. <https://www.gov.br/conselho-nacional-de-saude/pt-br/atos-normativos/resolucoes/2016/resolucao-no-510.pdf>. Acesso em: 24 set. 2026.
- Fiocruz – PCDaS (2026). Sistema de Informação sobre Mortalidade (SIM). Plataforma de Ciência de Dados Aplicada à Saúde, IciCT/Fiocruz. <https://pcdas.iciict.fiocruz.br/conjunto-de-dados/sistema-de-informacoes-de-mortalidade-sim/>. Cobertura temporal 1996–2024, a partir dos dados do DATASUS. Acesso em: 24 set. 2026.
- Ministério da Saúde (2026). SIM – Sistema de Informação sobre Mortalidade (1979–2019). Portal Brasileiro de Dados Abertos. <https://dados.gov.br/dados/conjuntos-dados/sim-1979-2019>. Licença Creative Commons Atribuição. Acesso em: 22 set. 2026.
- Morais, R. M. d. and Costa, A. L. (2017). Uma avaliação do Sistema de Informações sobre Mortalidade. *Saúde em Debate*, 41(spe):101–117. DOI: 10.1590/0103-11042017S09.
- Mujtaba, G., Shuib, L., Raj, R. G., Rajandram, R., Shaikh, K., and Al-Garadi, M. A. (2017). Automatic ICD-10 multi-class classification of cause of death from plaintext autopsy reports through expert-driven feature selection. *PLOS ONE*, 12(2):e0170242. DOI: 10.1371/journal.pone.0170242.
- Organização das Nações Unidas (2026). Objetivo de Desenvolvimento Sustentável 3: Saúde e bem-estar. ONU Brasil. <https://brasil.un.org/pt-br/sdgs/3>. Acesso em: 24 set. 2026.
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., and Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12:2825–2830.
- Santos, H. G. d., Nascimento, C. F. d., Izicki, R., Duarte, Y. A. d. O., and Chiavegatto Filho, A. D. P. (2019). Machine learning para análises preditivas em saúde: exemplo de aplicação para prever óbito em idosos de São Paulo, Brasil. *Cadernos de Saúde Pública*, 35(7):e00050818. DOI: 10.1590/0102-311X00050818.
- Silva, R. and Silva Neto, D. R. d. (2022). Inteligência artificial e previsão de óbito por Covid-19 no Brasil: uma análise comparativa entre os algoritmos Logistic Regression, Decision Tree e Random Forest. *Saúde em Debate*, 46(spe8):118–129. DOI: 10.1590/0103-11042022E809.
- World Health Organization (2019). International Statistical Classification of Diseases and Related Health Problems, 10th revision (ICD-10), version 2019. <https://icd.who.int/browse10/2019/en>. Acesso em: 24 set. 2026.